Université de Monastir
Institut Supérieur d'Informatique et de Mathématiques de Monastir
Département d'Informatique

TRAITEMENT ET ANALYSE DE DONNÉES AVEC PANDAS

Première Année Préparatoire Intégré
2025-2026

Séance 03

Rappel (Séance 2)

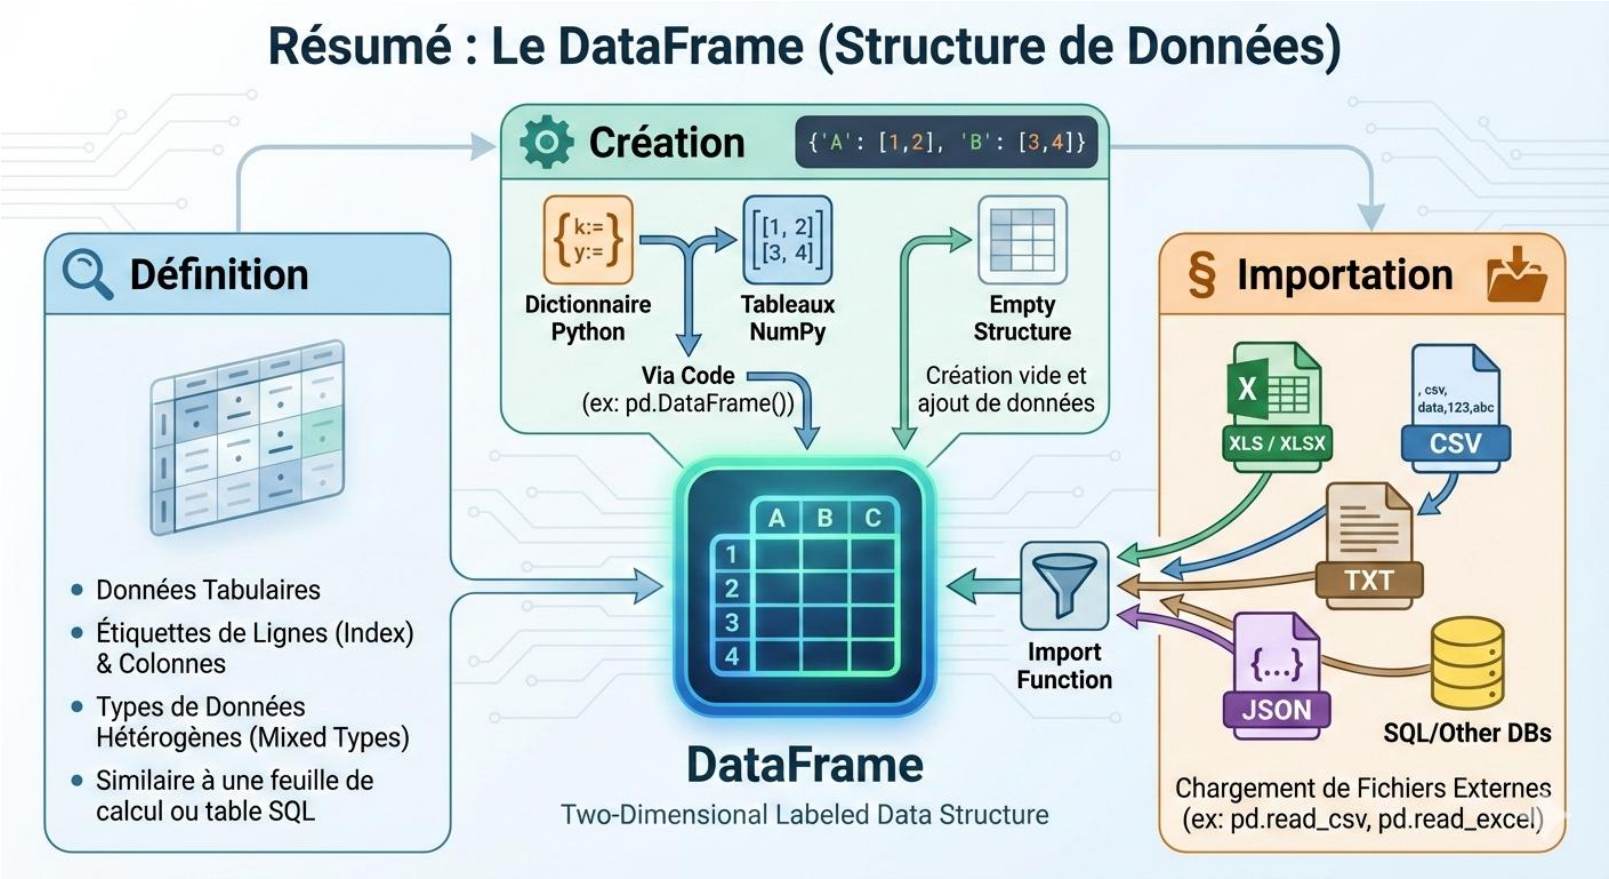

5

Manipulation de la structure d’un DataFrame

Afficher les dimensions d’un DataFrame

Afficher le nombre d’éléments d’un DataFrame

Afficher les informations concernant un DataFrame

Afficher un résumé rapide d’un DataFrame

Afficher les noms des colonnes d’un DataFrame

Renommer les libellés d’une ou de plusieurs colonnes

Supprimer des lignes ou des colonnes

5 Afficher les dimensions d'un DataFrame

Pour afficher le nombre de lignes et le nombre de colonnes d'un DataFrame, on utilise la propriété **shape** :

```
print (Id_DataFrame.shape)
```

```
print (sante.shape)
```

```
(173, 4)
```

La propriété **shape** peut être utilisée avec les **Series**.

5 Afficher le nombre d'éléments d'un DataFrame

Pour afficher le nombre total des éléments d'un DataFrame, on utilise la propriété **size** :

```
print (Id_DataFrame.size)
```

```
print (sante.size)
```

```
692
```

La propriété **size** peut être utilisée avec les **Series**.

5 Afficher les informations concernant un DataFrame

Pour afficher les informations relatives à un DataFrame, on utilise la méthode **info()** :

```
print (Id_DataFrame.info())
```

```
print (sante.info())
```

La méthode **info()** peut être utilisée avec les **Series**.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 169 entries, 0 to 168
Data columns (total 4 columns) :
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   Duration   169 non-null    int64
 1   Pulse      169 non-null    int64
 2   Maxpulse   169 non-null    int64
 3   Calories   164 non-null    float64
dtypes: float64(1), int64(3)
memory usage: 5.3 KB
```

→ Le type de l'objet
→ Les informations sur les indices
→ La liste des colonnes. Pour chaque colonne : son nom, le nombre de valeurs non nulles (Non-Null Count), son type de données (dtype)

→ Un résumé des types de données
→ L'occupation mémoire

5 Afficher un résumé rapide d'un DataFrame

Pour obtenir un résumé statistique rapide des colonnes numériques d'un DataFrame afin de comprendre la tendance centrale, la dispersion et la distribution des données, on utilise la méthode describe() :

```
print (Id_DataFrame.describe())
```

```
print (sante.describe())
```

La méthode **describe()** peut être utilisée avec les **Series**.

	Duration	Pulse	Maxpulse	Calories
count	169.000000	169.000000	169.000000	164.000000
mean	63.846154	107.461538	134.047337	375.790244
std	42.299949	14.510259	16.450434	266.379919
min	15.000000	80.000000	100.000000	50.300000
25%	45.000000	100.000000	124.000000	250.925000
50%	60.000000	105.000000	131.000000	318.600000
75%	60.000000	111.000000	141.000000	387.600000
max	300.000000	159.000000	184.000000	1860.400000

→ Nombre de valeurs non nulles
→ Moyennes
→ Écart-type
→ Valeur minimale
→ 1er quartile (Q1)
→ 2ème quartile : Médiane (Q2)
→ 3ème quartile (Q3)
→ Valeur maximale

5 Afficher les noms des colonnes d'un DataFrame

Pour afficher les noms des colonnes d'un DataFrame, on peut utiliser la propriété columns :

```
print (Id_DataFrame.columns)
```

```
print (sante.columns)
```

```
Index(['Duration', 'Pulse', 'Maxpulse', 'Calories'], dtype='object')
```

La propriété **columns** ne peut pas être utilisée avec les **Series**.

5 Renommer les noms des colonnes/indices d'un DataFrame

On utilise la méthode rename() :

```
Resultat = Id_DataFrame.rename(columns={ancien_nom:nouveau_nom, ...},
        index = { ancien_indice : nouveau_indice, ... } )
```

```
sante1 = sante.rename ( columns={"Duration":"c1"} )
print(sante)
print(sante1)
```

```
sante2 = sante.rename ( index = {172 : "fin"} )
print(sante)
print(sante2)
```

5 Supprimer une colonne d'un DataFrame

pop() est une méthode qui supprime un élément d'un objet pandas (colonne d'un DataFrame ou valeur d'une Series) et le retourne.

```
Id_Series = Id_DataFrame.pop ( "Nom_Colonne" )
```

On ne peut pas utiliser **pop()** pour supprimer plusieurs colonnes à la fois. **pop()** est conçue pour supprimer un seul élément et le retourner (sous forme de Series).

```
s = sante.pop ( "Calories" )
print(sante)
print(s)
```

5 Supprimer des colonnes d'un DataFrame

Pour supprimer une ou plusieurs colonnes, on procède comme suit :

```
Resultat = Id_DataFrame.drop ( columns=["Nom_Colonne1",...,"Nom_ColonneN"] )
```

ou bien

```
Resultat = Id_DataFrame.drop ( ["Nom_Colonne1",...,"Nom_ColonneN"], axis=1 )
```

```
aux1 = sante.drop ( columns = ["Duration", "Calories"] )
print(sante)
print(aux1)
```

```
aux2 = sante.drop ( ["Pulse"] , axis=1 )
print(sante)
print(aux2)
```

Pour la suppression d'une seule colonne, on peut ne pas mettre les crochets.

5 Supprimer des lignes d'un DataFrame

Pour supprimer une ou plusieurs lignes, on utilise la même méthode :

```
Resultat = Id_DataFrame.drop ( [Indice_Ligne1,...,Indice_LigneN] )
```

```
aux1=sante.drop([0])
aux2=sante.drop([0,5,100])
print(aux1, aux2)
```

Pour la suppression d'une seule ligne, on peut ne pas mettre les crochets.

Pour supprimer plusieurs lignes consécutives :

```
Resultat = Id_DataFrame.drop ( Id_DataFrame.index [ deb : fin ] )
```

```
aux3=sante.drop(sante.index[0:5])
print(aux3)
```

La suppression s'applique réellement aux éléments de deb à (fin-1).

6

Affichage des données d’un DataFrame

Afficher les données d’un DataFrame

(Lignes, Colonnes, Cellules)

6 Afficher le contenu d’un DataFrame

print(Id_DataFrame)

```
print(sante)
```

```
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
168        60    110       145     300.0
169        60    115       145     310.2
170        75    120       150     320.4
171        75    125       150     330.4
172        75    125       150     330.4

[173 rows x 4 columns]
```

6 Afficher le contenu d'une colonne

print(Id_DataFrame.Nom_Colonne) *ou bien*
print(Id_DataFrame["Nom_Colonne"])

print(sante.Duration) *ou bien* **print(sante["Duration"])**

```
0       60
1       60
2       60
3       45
4       45
        ..
168     60
169     60
170     75
171     75
172     75
Name: Duration, Length: 173, dtype: int64
```

6 Afficher le contenu de plusieurs colonnes

```
print ( Id_DataFrame [ ["Nom_Colonne1","Nom_Colonne2",...] ] )
```

```
print ( sante [ [ "Duration" , "Calories" ] ] )
```

```
     Duration  Calories
0          60     409.1
1          60     479.0
2          60     340.0
3          45     282.4
4          45     406.0
..        ...       ...
168        60     300.0
169        60     310.2
170        75     320.4
171        75     330.4
172        75     330.4

[173 rows x 2 columns]
```

6 Afficher le contenu d'une colonne entre 2 positions

Pour afficher le contenu d'une colonne entre une position initiale et une position finale – 1

```
print( Id_DataFrame.Nom_Colonne [Position_Initiale : Position_Finale] )
```

```
print(sante.Duration[0:10])
```

L'affichage réelle sera entre **0** et **9**.

```
0     60
1     60
2     60
3     45
4     45
5     60
6     60
7     60
8     45
9     30
Name: Duration, dtype: int64
```

6 Afficher le contenu d'une ligne

print (Id_DataFrame.loc [Indice_Ligne])

print(sante.loc[0]) ➔ Afficher le contenu de la première ligne.

```
Duration      60.0
Pulse        110.0
Maxpulse     130.0
Calories     409.1
Name: 0, dtype: float64
```

6 Afficher le contenu des n premières lignes

print (Id_DataFrame.head(n))

print(sante.head(5)) ➔ Afficher le contenu des 5 premières lignes du DataFrame "sante" (de 0 à 4).

```
   Duration  Pulse  Maxpulse  Calories
0        60    110       130     409.1
1        60    117       145     479.0
2        60    103       135     340.0
3        45    109       175     282.4
4        45    117       148     406.0
```

6 Afficher le contenu des n dernières lignes

print (Id_DataFrame.tail(n))

print(sante.tail(3)) ➔ Afficher le contenu des 3 dernières lignes du DataFrame "sante".

```
     Duration  Pulse  Maxpulse  Calories
170        75    120       150     320.4
171        75    125       150     330.4
172        75    125       150     330.4
```

6 Afficher le contenu des lignes entre 2 positions

print (Id_DataFrame.loc [Indice_LigneDeb : Indice_LigneFin])

print(sante.loc[10:20]) ➔ Afficher le contenu des lignes entre la position 10 et 20.

```
    Duration  Pulse  Maxpulse  Calories
10        60     98       124     269.0
11        60    103       147     329.3
12        60    100       120     250.7
13        60    106       128     345.3
14        60    104       132     379.3
15        60     98       123     275.0
16        60     98       120     215.2
17        60    100       120     300.0
18        45     90       112       NaN
19        60    103       123     323.0
20        45     97       125     243.0
```

6 Afficher le contenu d’une cellule

print (Id_DataFrame.loc [Indice_Ligne, Indice_Colonne])

print(sante.loc[3,’Pulse’]) ➔ Afficher le contenu de la cellule appartenant à la ligne 3 et à la colonne ‘Pulse’ du DataFrame "sante".

```
109
```

7

Manipulation des données d’un DataFrame

Modifier le contenu d’un DataFrame

Ajouter une colonne à un DataFrame

Nettoyer un DataFrame

7 Modifier le contenu d’un DataFrame

Pour modifier le contenu d’une cellule dans un DataFrame :

```
Id_DataFrame.loc[Indice_Ligne, Nom_Colonne]=Valeur
```

```
sante.loc[0,"Maxpulse"]=132
```

Pour modifier le contenu d’une ligne d’un DataFrame :

```
Id_DataFrame.loc[Indice_Ligne]=[Liste_Valeur]
```

```
sante.loc[0]=[50,100,145,None]
```

7 Ajouter une colonne à un DataFrame

Pour ajouter une colonne remplie par des données dans un DataFrame :

```
Id_DataFrame["Nom_Colonne"]=valeur (ou formule)
```

```
sante["Test"]=50
```

```
sante["Test"]=sante["Maxpulse"]-sante["Pulse"]
```

7 Nettoyer un DataFrame

Pour supprimer les doublons d'un DataFrame, on utilise la méthode suivante :

```
Resultat = Id_DataFrame.drop_duplicates()
```

```
sante1 = sante.drop_duplicates()
print(sante.shape)
print(sante1.shape)
```

```
(173, 4)
(162, 4)
```

7 Nettoyer un DataFrame

Pour supprimer les contenus vides dans un DataFrame, on peut procéder ainsi :

Supprimer toutes les lignes contenant des valeurs nulles :

```
Resultat = Id_DataFrame.dropna()
```

```
sante2 = sante1.dropna()
```

Supprimer toutes les colonnes contenant des valeurs nulles :

```
Resultat = Id_DtaFrame.dropna(axis=1)
```

```
sante3 = sante1.dropna(axis=1)
```